Olist 巴西电商数据分析

从数据处理、指标体系到预测建模的完整作品集报告

数据时间范围：2016-09-04 至 2018-10-17

报告定位：数据分析岗位求职作品集

数据来源：Kaggle Olist 数据集

1. 项目摘要

本项目基于 99,441 笔订单、96,096 名唯一客户和 3,086
个卖家，完成销售表现、物流效率、客户评价和客户复购分析。订单级销售额约为 15,843,553，平均客单价为 159.33。在有完整配送日期的订单中，延迟率为 8.1%；在有评价的订单中，低评分率为 14.6%。

报告同时建立订单延迟预测和低评分预测两个模型。建模采用时间顺序切分，避免将未来信息带入训练特征。模型结果用于风险排序和运营预警，不用于因果判断。

订单量	99,441
销售额	15,843,553
客单价	159.33
延迟率	8.1%
低评分率	14.6%
复购客户率	3.1%

2. 数据来源与数据处理

原始数据包括订单、订单明细、支付、评价、客户、卖家、商品、地理位置和类别翻译 9 张表。项目保留原始数据，并将多表数据统一整理为订单级分析表和商品明细级分析表。

订单金额采用商品价格与运费的订单级汇总，避免订单明细和支付明细连接后重复累计。延迟标签只在实际送达日期和预计送达日期同时存在时计算。评价标签只在评价分数存在时计算。

表级检查	结果
orders_with_purchase_date	99,441
orders_with_customer	99,441
orders_with_item	98,666
delivered_orders	96,478
orders_with_late_label	96,476
orders_with_review_label	98,673
negative_delivery_days	0
negative_order_value	0
duplicate_order_ids	0

数据处理步骤：先保留原始表，再将订单明细按 order_id 汇总，将支付记录按 order_id 汇总，将评价按 order_id 汇总，最后与客户、卖家和商品维度关联。订单级金额由商品金额和运费组成，支付金额只用于独立核对。模型特征按订单时间排序后计算历史卖家表现和客户历史订单数，避免当前订单标签进入当前特征。

3. 指标体系与业务分析

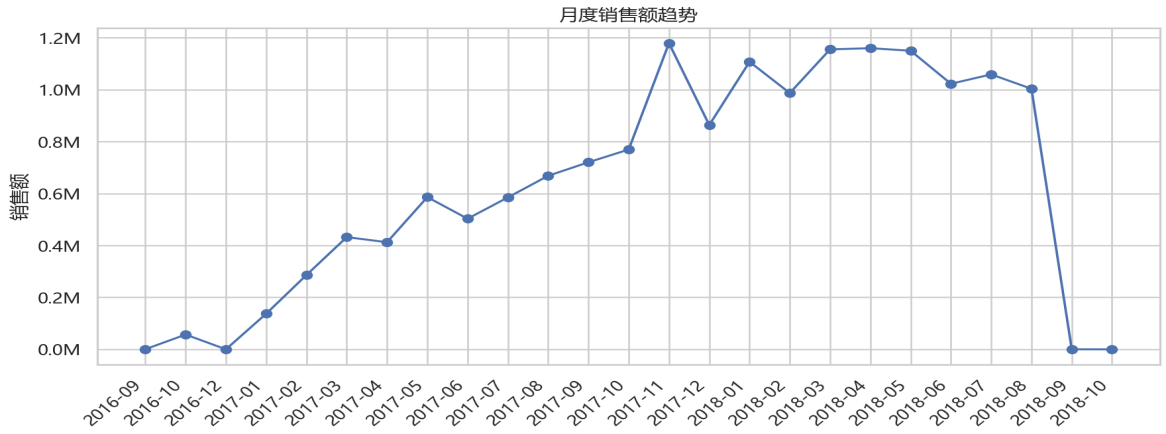
指标按订单、客户、卖家、商品类别和月份五类粒度组织。销售指标用于识别收入来源，物流指标用于定位履约风险，评价指标用于衡量体验，RFM 指标用于识别客户价值。

核心指标口径

指标	计算口径	粒度
销售额	商品金额 + 运费金额	订单
客单价	订单销售额 / 订单数	订单
延迟率	延迟订单 / 有完整配送日期订单	订单
低评分率	评分 <= 2 的订单 / 有评价订单	订单
复购客户率	购买次数 > 1 的唯一客户 / 唯一客户	客户
RFM	最近购买、购买频次、累计金额分位数	客户

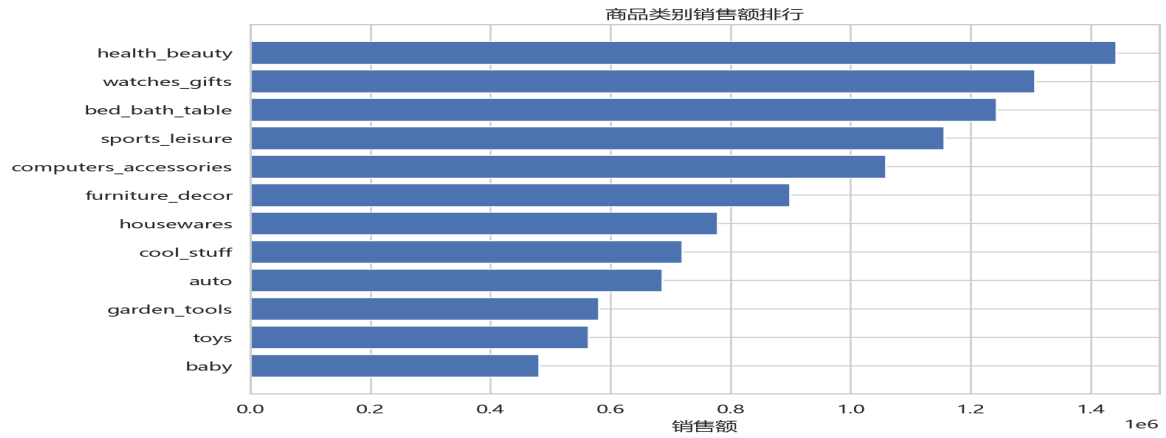
初步业务发现：销售额最高的商品类别为 health_beauty，销售额约 1,441,978；客户销售额最高的州为 SP，销售额约 5,921,678；销售额最高月份为 2017-11。这些结果用于提出分析方向，不等同于因果结论。

月度销售趋势



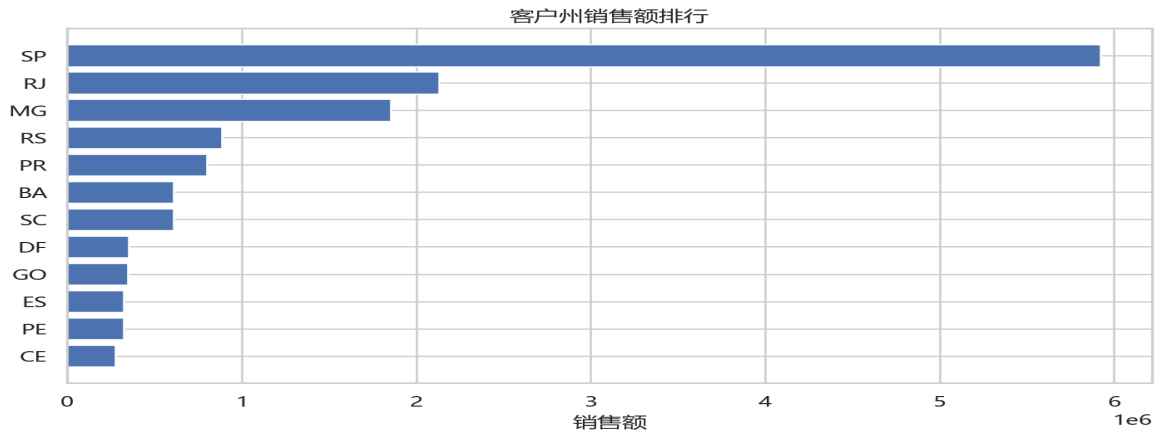
观察销售额的时间变化和季节性。

商品类别销售排行



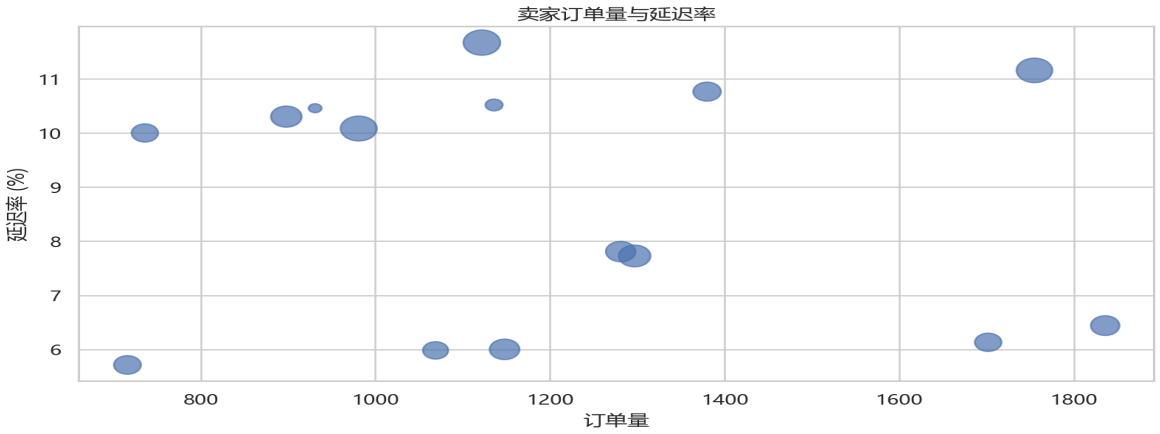
识别贡献主要销售额的商品类别。

客户州销售排行



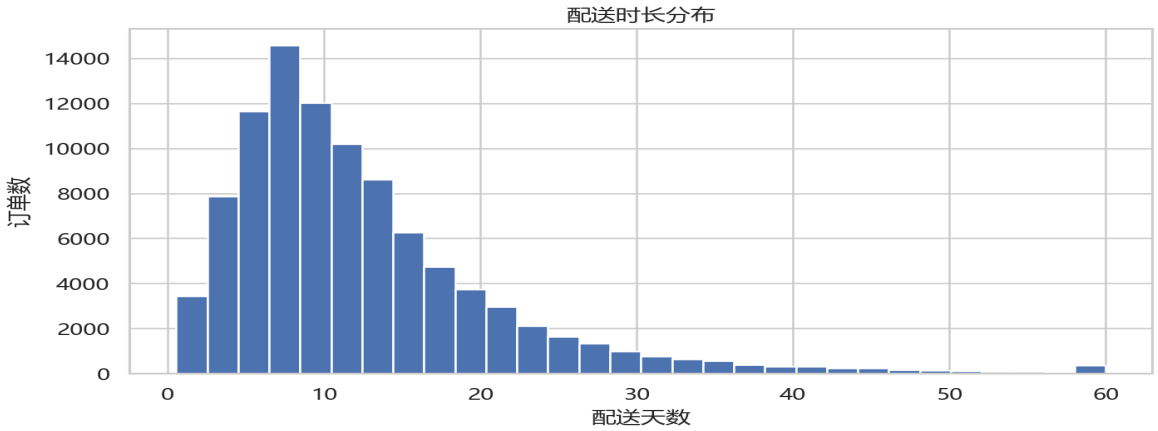
比较不同客户地区的销售贡献。

卖家订单量与延迟率



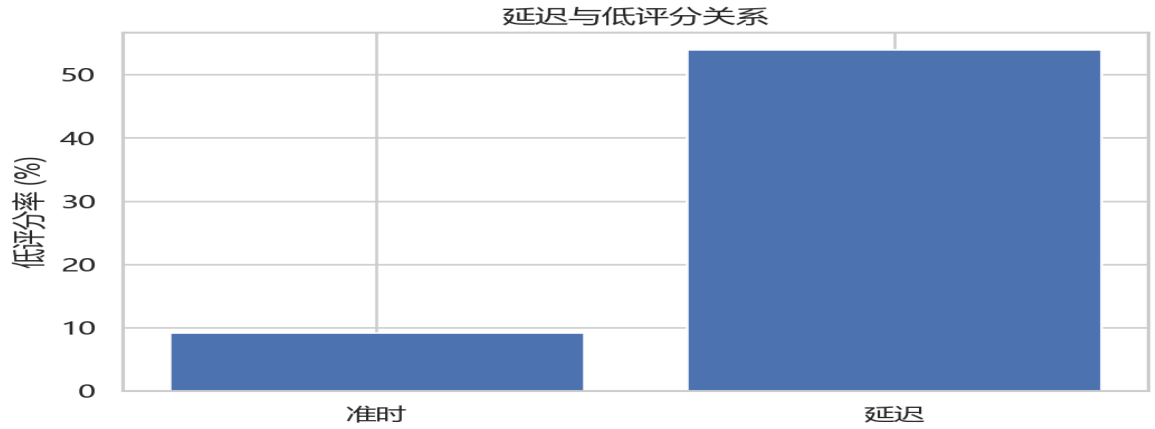
同时观察卖家规模和履约风险。

配送时长分布



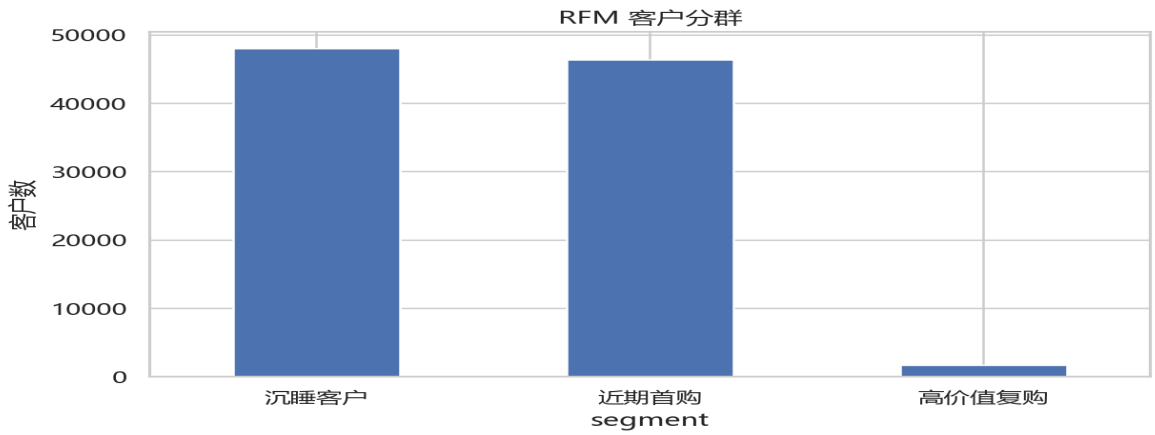
检查配送时长的集中区间和长尾。

延迟与低评分关系



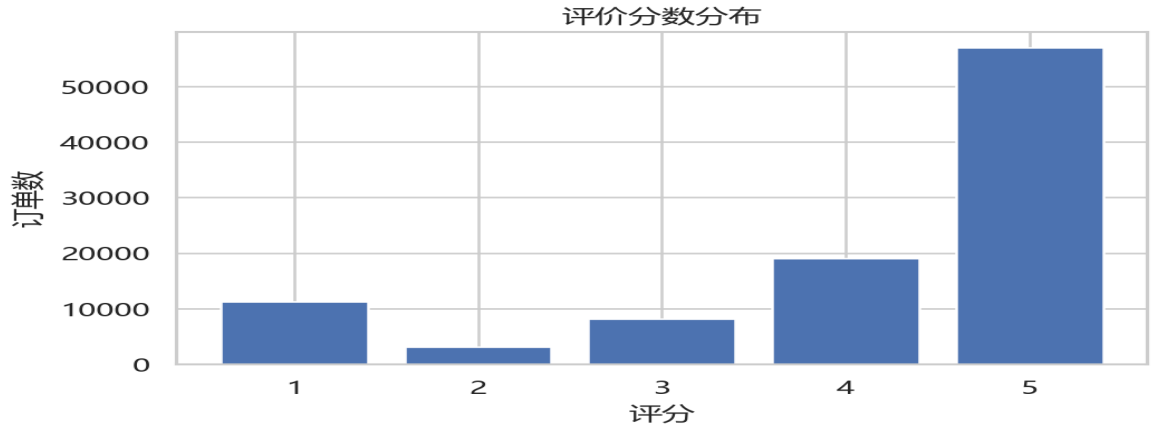
比较准时与延迟订单的低评分率。

RFM 客户分群



区分近期复购、高价值、首购和沉睡客户。

评价分数分布



观察客户评价的整体分布。

预测建模方法说明

两个任务均按照订单时间排序，前 70% 为训练集，中间 15% 为验证集，最后 15% 为测试集。Logistic Regression 用于提供可解释基线，Random Forest 用于捕捉非线性关系。分类特征使用 One-Hot 编码，数值特征使用中位数填补并标准化。阈值在验证集上按 F1 选择，再固定到测试集评估。

ROC-AUC 衡量模型区分正负样本的排序能力，PR-AUC 更适合正样本比例较低的风险识别任务。Precision 表示预测为风险的订单中实际风险订单的比例，Recall 表示实际风险订单中被识别出来的比例，F1 是 Precision 和 Recall 的综合指标。实际部署时应结合一次误报和一次漏报的业务成本重新确定阈值。

未来信息控制：延迟预测不使用实际送达时间和评价结果；低评分预测不使用实际配送结果和评价文本；卖家历史变量只使用当前订单之前的累计记录。

4. 订单延迟预测

样本量：96,476；正样本率：8.1%；训练集、验证集、测试集数量分别为 67,533、14,471、14,472。

模型	ROC-AUC	PR-AUC	Precision	Recall	F1	阈值
logistic_regression	0.509	0.069	0.063	0.223	0.098	0.60
random_forest	0.453	0.058	0.053	0.104	0.070	0.62

logistic_regression 重要特征：payment_type_unknown, seller_state_MA, seller_state_RO, primary_category_art, customer_state_AL, primary_category_cds_dvds_musicals

random_forest 重要特征：seller_prev_late_rate, freight_value, customer_state_SP, seller_history_orders, customer_state_RJ, item_value

模型特征来自订单产生前或订单确认时可获得的信息。实际送达日期和评价结果仅用于构造标签和离线评估，没有作为输入特征。

5. 低评分预测

样本量：98,673；正样本率：14.6%；训练集、验证集、测试集数量分别为 69,071、14,801、14,801。

模型	ROC-AUC	PR-AUC	Precision	Recall	F1	阈值
logistic_regression	0.601	0.210	0.160	0.377	0.224	0.54
random_forest	0.594	0.213	0.170	0.359	0.231	0.52

logistic_regression 重要特征：seller_state_unknown, primary_category_cds_dvds_musicals, seller_state_PA, seller_state_AC, primary_category_food_drink, primary_category_flowers

random_forest 重要特征：freight_value, seller_prev_late_rate, item_count, item_value, product_count, seller_history_orders

低评分预测用于提前识别可能产生负面体验的订单。该模型不使用实际配送结果和评价文本，因此更接近下单阶段的预警场景。

6. 业务建议

第一，优先将延迟预测用于物流预警，对高风险订单提前检查卖家备货和配送安排。第二，对低评分风险较高的订单加强配送承诺管理和客户沟通。第三，按卖家订单规模和延迟率联合识别重点卖家，避免只按订单量进行评价。第四，针对高价值复购客户建立差异化服务和复购激励。第五，在模型上线前持续监控时间漂移、特征缺失和阈值下的误报漏报。

项目限制：Olist 数据是历史匿名数据，缺少利润、营销成本、库存和真实物流节点等变量。分析结果描述相关关系，不应解释为因果关系。预测模型需要在新的时间窗口上重新验证。

附录：完整字段说明、清洗规则、指标口径、模型参数、SQL 示例和运行方式见项目目录中的 README、docs/data_dictionary.md、docs/sql_examples.sql 和 JSON 结果文件。